



Metodología de investigación cuantitativa
y Análisis de datos Estadísticos.



Análisis de datos en R Studio

Ayudantías Metodología Cuantitativa 2
Antropología 2025



No hay manipulación de datos sin decisiones políticas: la ilusión de neutralidad en las categorías



La antropología ha cuestionado la idea de que el conocimiento puede ser totalmente objetivo, neutral o aséptico. Las decisiones metodológicas (qué medir, cómo clasificar, qué eliminar, cómo codificar) no son solo técnicas, sino que **son formas de intervenir en la realidad y de construir ciertos mundos como más legibles que otros.**

Autores como Bowker y Star (1999) han mostrado cómo las clasificaciones y estándares invisibles organizan nuestra forma de ver el mundo.

- Toda clasificación es una forma de poder: decide qué cosas son visibles y cuáles se invisibilizan.
- Los estándares y categorías que parecen neutros son en realidad productos históricos y sociales.
- Estos sistemas son "infraestructuras invisibles": no se ven, pero organizan lo que consideramos normal o verdadero.

Imagina un estudio antropológico sobre mortalidad en zonas rurales. Al acceder a los registros oficiales, se encuentra que muchas muertes están clasificadas como "causa desconocida" o "paro cardiorrespiratorio". Sin embargo, en las entrevistas con familiares, emergen narrativas sobre enfermedades respiratorias, contaminación del agua, o efectos de agrotóxicos.

¿Qué implica aceptar esa categoría institucional sin cuestionarla? ¿Qué formas locales de nombrar la enfermedad o la muerte quedan fuera del registro?


Manipular datos no es solo una tarea técnica; también es una práctica epistemológica que moldea qué vidas y experiencias entran en la mirada cuantitativa.

No hay transformación de datos sin decisiones políticas: ¿Qué tiene que ver esto con data wrangling?



Cuando realizamos data wrangling —por ejemplo, cuando normalizamos categorías, imputamos datos faltantes o eliminamos valores "outliers"— estamos tomando decisiones que afectan:


- ¿Qué experiencias se consideran representativas o válidas?
- ¿Qué poblaciones quedan fuera del análisis por "no encajar"?
- ¿Qué aspectos de la realidad serán modelados y representados cuantitativamente, y cuáles no?



¿Qué pasa si una experiencia no cabe en nuestras variables? ¿Quién queda fuera?



Proceso de programación para el análisis de datos



Códigos y funciones básicas



Procesamiento de datos



Flujograma de un proyecto Data Science




RECOLECCIÓN DE DATOS

PROCESAMIENTO DE LA INFORMACIÓN

PRESENTACIÓN Y PUBLICACIÓN DE LOS RESULTADOS

Flujo de trabajo




Data Wrangling: manipulación de datos




Proceso de limpieza y transformación de datos desordenados o incompletos para que puedan ser usados fácilmente en un análisis.

- Limpieza de datos
- Transformación de variables



Imagina que tienes una bolsa con frutas de todo tipo, algunas sucias, otras con partes malas, y mezcladas sin orden. Data wrangling es como lavar, pelar, cortar y ordenar esas frutas en platos, listas para comer o cocinar.

Herramientas tidyverse: filtrar, seleccionar, mutar y organizar según cierta categoría



Data Wrangling



Exploración de datos

¿Qué tengo aquí?"

¿Qué columnas hay?

¿Qué tipo de datos contiene cada una?

Ejemplo: Descubres que la variable "ingreso" tiene valores como "5000 dólares", "cinco mil", y "5000", lo cual implica que hay que estandarizar.

head()

glimpse()

str()

summary()

names()

Publicar

Una vez limpios y ordenados, los datos están listos para ser analizados o compartidos con otros/as. Aquí también se puede exportar la tabla como archivo (.csv, .xlsx, etc.).

Ejemplo: Guardar la base de datos final para hacer gráficos o correr modelos estadísticos.

```
writexl::write_xlsx(datos, "datos.xlsx")
```

Validar

Se revisa que los datos sean coherentes y correctos.

Ejemplo: Verificar que no haya datos duplicados.

```
duplicated(datos)
```



Enriquecer

Se refiere a añadir nuevas variables o más información útil.

Ejemplo: Calculas una nueva variable "índice de masa corporal" a partir de peso y altura.

```
mutate() case_when()
```

Estructurar los datos

Es el momento de dar forma a los datos. Algunas veces los datos vienen en un formato que no es útil. ¿Cómo organizo mejor esta información?

```
rename()
```

```
select()
```

Limpieza de datos


Aquí se eliminan errores, se corrigen datos incorrectos, se rellenan valores faltantes y se estandarizan formatos.

Ejemplo: Cambiar "masculino", "M", "hombre" todos a "Hombre".

Filtrar NA.


```
mutate()
```

```
filter()
```






Ejemplo




```
library(tidyverse)

datos_limpios <- datos %>%
  rename(edad = EDAD, sexo = SEX0) %>%
  mutate(sexo = tolower(sexo),
         grupo_edad = case_when(
           edad < 18 ~ "menor",
           edad >= 18 & edad < 60 ~ "adulto",
           TRUE ~ "mayor"
         )) %>%
  filter(!is.na(edad)) %>%
  distinct() %>%
  select(nombre, edad, sexo, grupo_edad)

write.csv(datos_limpios, "datos_limpios.csv")
```



Herramientas tidyverse: filtrar,
seleccionar, mutar integradas





¿Dudas?





Vamos a la práctica

